Лабораторная работа: Распознавание объектов на фотографиях (CIFAR-10)
Цель работы: Ознакомиться со сверточными нейронными сетями (CNN), изучить их применение для задачи классификации изображений, а также исследовать работу слоя регуляризации Dropout и влияние размера ядра свертки.
Теоретическая часть:
1. Почему сверточные сети (CNN)
В предыдущих лабораторных работах (например, MNIST) мы использовали полносвязные сети (MLP). Однако MLP неэффективны для больших изображений:
Проблема "проклятия размерности": Изображение CIFAR-10 имеет размер 32x32x3 (ширина x высота x цветные каналы RGB). Если подать его как "вытянутый" вектор (32*32*3 = 3072 элемента) в первый скрытый слой MLP с 100 нейронами, только этот слой будет иметь 3072 * 100 = 307,200 параметров (весов)! Для изображений большего размера количество параметров становится огромным, что приводит к переобучению и затрудняет обучение.
Игнорирование пространственной структуры: MLP "забывает" о том, что пиксели расположены в двумерном пространстве и имеют соседей. Он трактует их как независимые признаки.
CNN решают эти проблемы:
Локальность: Используют операцию свёртки (convolution), которая применяет небольшое "окно" (ядро) к локальным участкам изображения. Это предполагает, что пиксели, находящиеся рядом, сильнее связаны между собой, чем отдаленные.
Параметрическая эффективность: Одно и то же ядро свертки применяется ко всему изображению. Это означает, что один набор весов ядра используется многократно, значительно уменьшая общее количество обучаемых параметров по сравнению с MLP.
Инвариантность к сдвигу: Если важный признак (например, край объекта) появляется в разных частях изображения, свертка может его обнаружить в любом месте.
2. Основные слои CNN
Сверточный слой (Conv2D)
Ядро свертки (Filter/Kernel): Маленькая матрица весов (например, 3x3 или 5x5). Для цветных изображений ядро имеет глубину, равную количеству каналов входа (например, 3x3x3).
Операция: Ядро "скользит" по входному изображению (или карте признаков), вычисляя скалярное произведение между весами ядра и значениями пикселей под ним. Результат записывается в выходную карту признаков (feature map).
Глубина слоя: Определяет количество различных ядер, применяемых к входу. Каждое ядро выделяет свой тип признака (например, горизонтальные края, вертикальные края, диагонали). Выходная глубина = количество ядер.
Гиперпараметры:
filters: Количество ядер (глубина выхода).
kernel_size: Размер ядра (например, (3, 3)).
strides: Шаг скольжения ядра (обычно 1).
padding: 'valid' (без дополнения, размер выхода уменьшается) или 'same' (добавляются нули по краям, размер выхода = размер входа при strides=1).
Слой подвыборки (Pooling)
Цель: Уменьшить пространственные размеры (ширину и высоту) карт признаков. Это снижает количество вычислений, уменьшает количество параметров и помогает достичь некоторой инвариантности к небольшим сдвигам и искажениям.
Типы:
MaxPooling2D: Для каждого "окна" (например, 2x2) выбирает максимальное значение.
AveragePooling2D: Выбирает среднее значение по окну.
Гиперпараметры:
pool_size: Размер окна (например, (2, 2)).
strides: Шаг скольжения окна.
Выравнивающий слой (Flatten)
Преобразует 3D тензор (высота x ширина x глубина) в 1D вектор. Используется перед полносвязными слоями.
Полносвязный слой (Dense)
Стандартный слой, как в MLP. Используется в конце сети для классификации на основе признаков, извлеченных сверточными слоями.
Слой регуляризации Dropout
Цель: Борьба с переобучением.
Как работает: С определенной вероятностью (rate) случайным образом обнуляет (выключает) выходы части нейронов слоя на каждой итерации обучения.
Эффект: Заставляет нейроны не полагаться слишком сильно на выходы конкретных других нейронов, повышая обобщающую способность. Нейросеть учится более "распределенному" представлению информации.
Важно: Dropout автоматически отключается во время оценки/предсказания.
3. Архитектура типичной CNN
Типичная CNN состоит из чередующихся блоков:
Сверточный слой (Conv2D) + Функция активации (обычно ReLU)
Сверточный слой (Conv2D) + ReLU (необязательно)
Слой подвыборки (MaxPooling2D)
Повтор блоков 1-3 несколько раз (глубина сети).
Flatten
Один или несколько полносвязных слоев (Dense) + ReLU
Финальный полносвязный слой (Dense) с softmax активацией для многоклассовой классификации.
4. Набор данных CIFAR-10
Описание: Стандартный набор данных для оценки алгоритмов классификации изображений.
Содержание: 60,000 цветных изображений размером 32x32 пикселей.
Классы (10):
Самолет (airplane)
Автомобиль (automobile)
Птица (bird)
Кошка (cat)
Олень (deer)
Собака (dog)
Лягушка (frog)
Лошадь (horse)
Корабль (ship)
Грузовик (truck)
Разделение:
Обучающая выборка: 50,000 изображений.
Тестовая выборка: 10,000 изображений.
Формат данных:
X_train: Массив формы (50000, 32, 32, 3) (Numpy array).
y_train: Массив меток формы (50000,) с целыми числами от 0 до 9.
X_test, y_test: Аналогично для теста.
5. Функция активации и функция потерь
ReLU (Rectified Linear Unit): f(x) = max(0, x). Используется в скрытых слоях (Conv и Dense). Помогает сети учиться нелинейным зависимостям и ускоряет обучение.
Softmax: Используется в выходном слое для многоклассовой классификации. Преобразует выходы в распределение вероятностей (сумма = 1).
Функция потерь: categorical_crossentropy (категориальная перекрестная энтропия). Подходит для многоклассовой классификации с one-hot кодированными метками. Штрафует модель за отклонение предсказанного распределения вероятностей от истинного.
6. Оптимизатор
Adam – популярный адаптивный оптимизатор, который часто используется по умолчанию. Он комбинирует идеи Momentum и RMSprop.
7. Метрика
accuracy (точность) – доля правильно классифицированных изображений.